Escola de Artes Ciências e Humanidades: Teste de Software

Aluno: Adilson Lopes Khouri

1 de julho de 2019

Sumário

Contextualização

1. Classificadores definem uma superfície de decisão para classificar dados (em até n-classes)

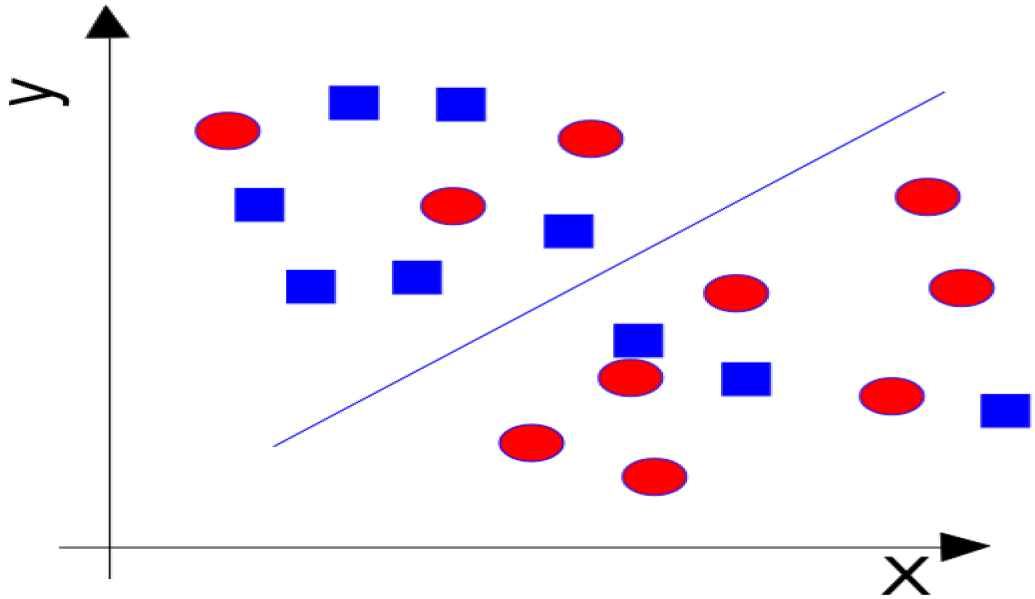

Figura: Exemplo utópico de fronteira de decisão, desenhado pelo autor

Contextualização

1. Os classificadores escolhem uma das retas azuis possíveis (há infinitas possibilidades) para ser a fronteira de decisão.
2. O problema acima é utópico, tipicamente as classes não ficam separadas perfeitamente.

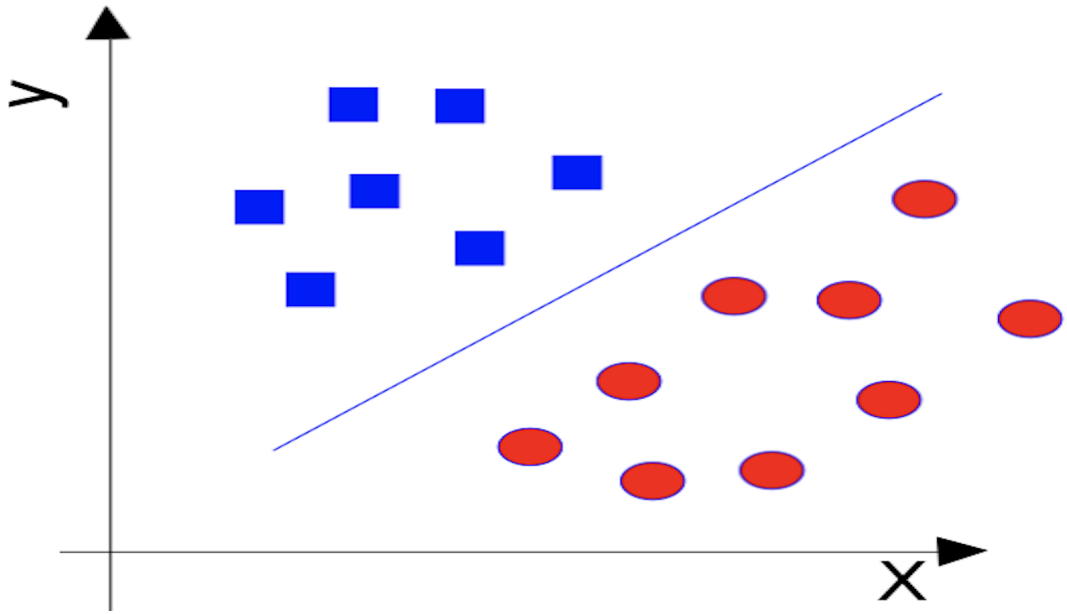

Figura: Exemplo real de fronteira de decisão, desenhado pelo autor

Contextualização

1. Para definir a fronteira é usado um algoritmo de otimização (que minimiza o erro de classificação)
2. **É considerado normal ter erros de classificação dado a natureza não determinística dos algoritmos de Machine Learning**

Contextualização

Quando ocorre um erro de classificação em algoritmos de machine learning podem ter várias razões (não mutuamente exclusivas):

1. Dados de treino insuficientes/viesados
2. Arquitetura do algoritmo mal planejada
3. O algoritmo aprendeu a função errada
4. Bug no código fonte
5. Variação na distribuição das principais variáveis usadas pelo modelo
6. Bug em outros sistemas que alimentam os dados do modelo

Contextualização

1. Além dos problemas citados há modelos caixa preta (não é possível entender como o modelo toma decisões[de onde foi criado o score?])
2. Regressão logística e CART são exemplos de algoritmos interpretáveis (é possível entender como foi tomada a decisão)

Contextualização

1. Dados todos esses problemas citados há linhas de pesquisa para cada um deles.
2. Os artigos LIME [1], SHAP [2] e Manifold [3] tentam resolver o problema de quais variáveis são mais relevantes para modelos caixa preta.
3. O último artigo [4] trata sobre identificação de bugs em código fonte de algoritmos de Machine Learning

Artigo 01

1. “Why Should I Trust You?” Explaining the Predictions of Any Classifier [1]

Lime - overview

1. É agnóstico (não assume nada sobre o modelo, dessa forma, funciona para qualquer modelo)
2. Realiza uma interpretação Local do score gerado pelo modelo.
3. Um ponto falho é que a interpretação foi avaliada usando modelos pequenos (até 10 features) interpretáveis (explicar por que é falho)
4. Um ponto fraco da técnica é que a função de distância depende do tipo de dado de input (texto, imagem, numérico...)

Lime - funcionamento

1. Escolhe uma instância que deseja interpretar
2. Seleciona outras instâncias próximas a ela (usando uma métrica de distância D)
3. Usando a amostra executa uma logística para aprender, localmente, quais as variáveis mais importantes

Lime - fronteira de decisão

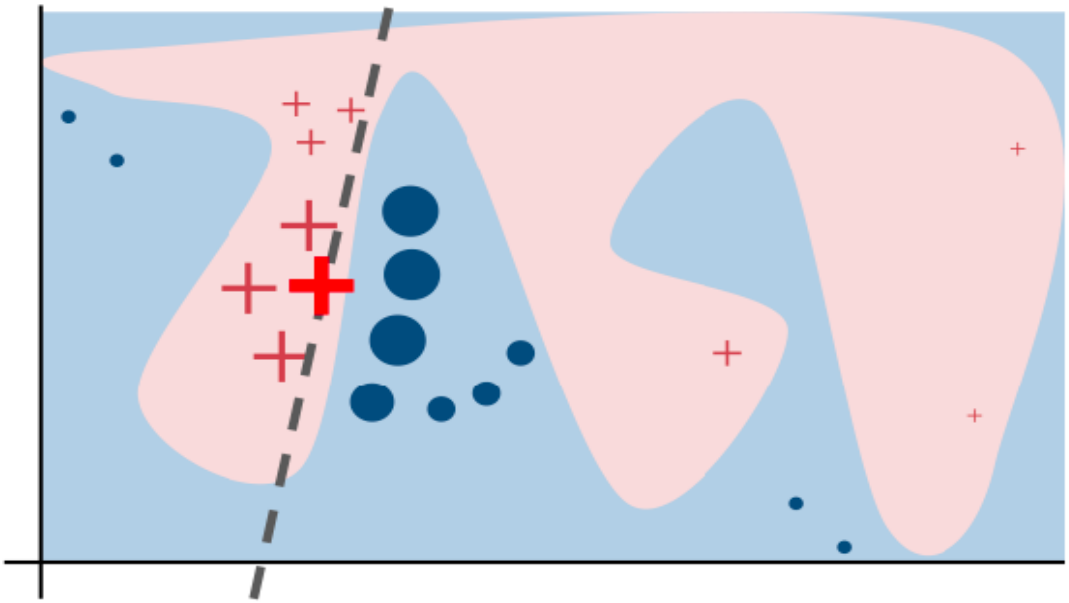

Figura: LIME fronteira de decisão [1]

Artigo 02

1. Manifold: A Model-Agnostic Framework for Interpretation and Diagnosis of Machine Learning Models [3]

Manifold - overview

1. É um framework para ajudar o cientista a localizar falhas no modelo, para tal, os autores automatizam tarefas típicas para depurar modelos.
2. Para tal, os autores criaram uma “matriz de confusão” que relaciona modelos e classes, com essa matriz é possível avaliar visualmente onde os modelos não concordam.

Manifold - overview

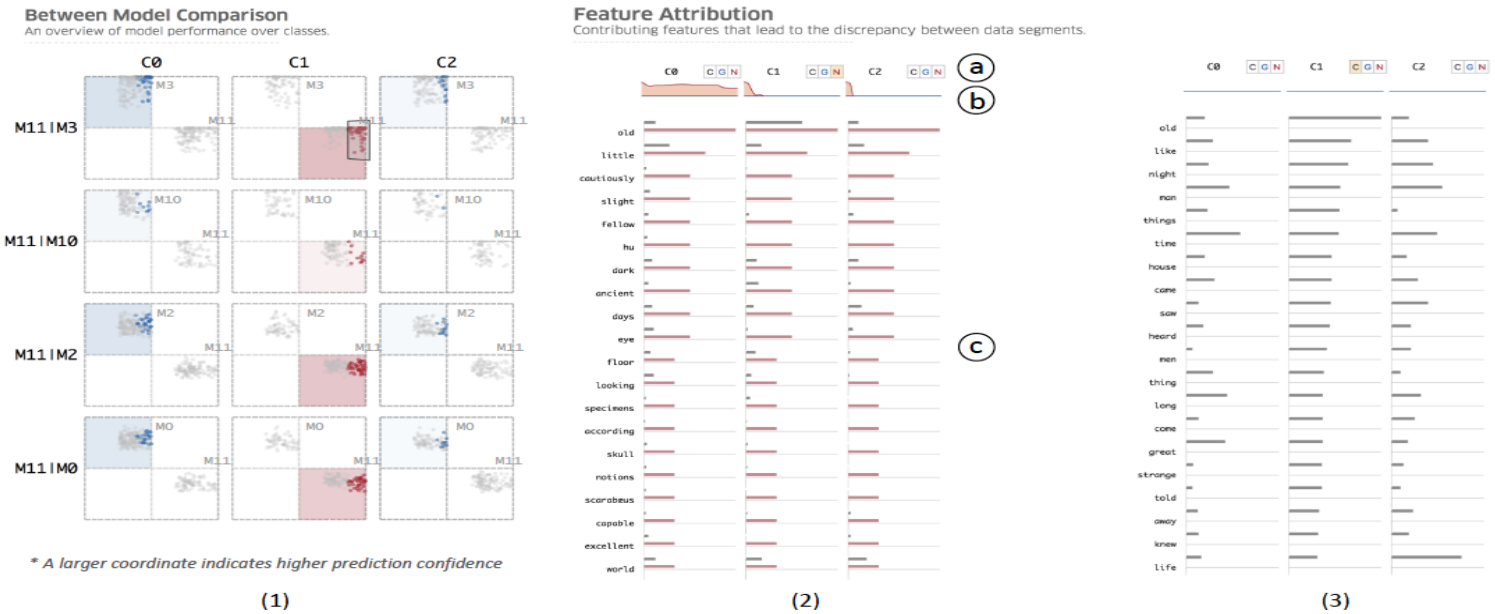

Figura: Visualização sugerida pelo manifold [3]

Manifold - overview

1. Após selecionar a célula (tipicamente será escolhida a células de diferença Q1, Q3) é exibida uma comparação da distribuição de variáveis das instâncias daquela célula.
2. No próximo gráfico é exibida uma sumarização dos valores (TF-IDF) das features, das instâncias selecionadas, e das instâncias pertencentes a cada classe.
3. Pode-se usar o gráfico do meio para avaliar quais features são mais relevantes para classificar uma instância em determinada classe

Manifold - funcionamento

1. A comparação de modelos é feita por meio de visualização das probabilidades e classes verdadeiras em uma “matriz de confusão”

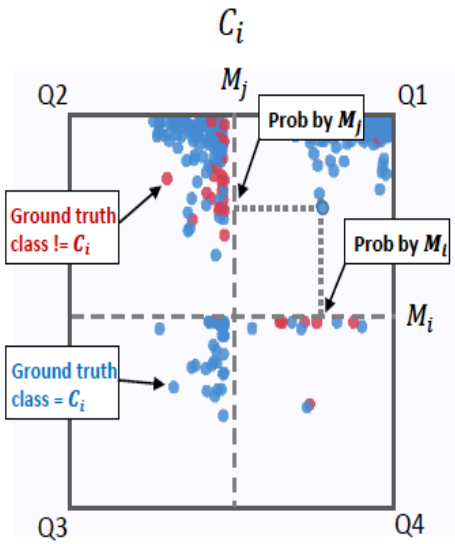

	Instances in blue (GT class = C_i)	Instances in red (GT class != C_i)	Agreement
Q1	Class predicted by M_i = C_i (M_i correct) Class predicted by M_j = C_i (M_j correct) TP for M_i and M_j	Class predicted by M_i = C_i (M_i wrong) Class predicted by M_j = C_i (M_j wrong) FP for M_i and M_j	Agree
Q2	Class predicted by M_i != C_i (M_i wrong) Class predicted by M_j = C_i (M_j correct) FN for M_i, TP for M_j	Class predicted by M_i != C_i (M_i correct) Class predicted by M_j = C_i (M_j wrong) TN for M_i, FP for M_j	Disagree
Q3	Class predicted by M_i != C_i (M_i wrong) Class predicted by M_j != C_i (M_j wrong) FN for M_i and M_j	Class predicted by M_i != C_i (M_i correct) Class predicted by M_j != C_i (M_j correct) TN for M_i and M_j	Agree
Q4	Class predicted by M_i = C_i (M_i correct) Class predicted by M_j != C_i (M_j wrong) TP for M_i, FN for M_j	Class predicted by M_i = C_i (M_i wrong) Class predicted by M_j != C_i (M_j correct) FP for M_i, TN for M_j	Disagree

Figura: Matriz de confusão usada pelo Manifold [3]

Manifold - funcionamento

1. A avaliação de importância de features (segundo gráfico da esquerda para direita) é realizada usando uma métrica como TF-IDF para a classe e para o conjunto de dados classificados
2. Os gráficos acima, que não é a distribuição de variáveis mas a *Kullback-Leibler divergence*, indica o quanto a distribuição dos itens selecionados é parecida com a classe em questão
3. O último gráfico (da esquerda para direita) mostra a distribuição de features por classe, sumarizadas por TD-IDF

Artigo 03

1. Consistent Individualized Feature Attribution for Tree Ensembles [2]

Shap - overview

1. Não é agnóstico (funciona apenas para ensemble de árvore de decisão)
2. Realiza uma interpretação Local do score gerado pelo modelo.
3. Citam o problema de incosistência (score alto para variáveis que não são importantes e o caso contrário)
4. Um ponto falho é que o SHAP foi avaliado perguntando para algumas pessoas (os autores não citam esse número) quais features eram mais relevantes.

Shap - funcionamento

1. Realiza uma perturbação do dado de entrada, roda um modelo aditivo sobre o dado orignal e sobre o perturbado.
2. Interpreta o modelo aditivo para dizer o quanto a variável foi explicativa para aquela decisão
3. A diferença em relação ao LIME é que no modelo aditivo encontro o phi (equivalente ao beta da regressão) com probabilidade condicional, a logística usa uma técnica de otimização (e.g. Least square)

SHAP - output

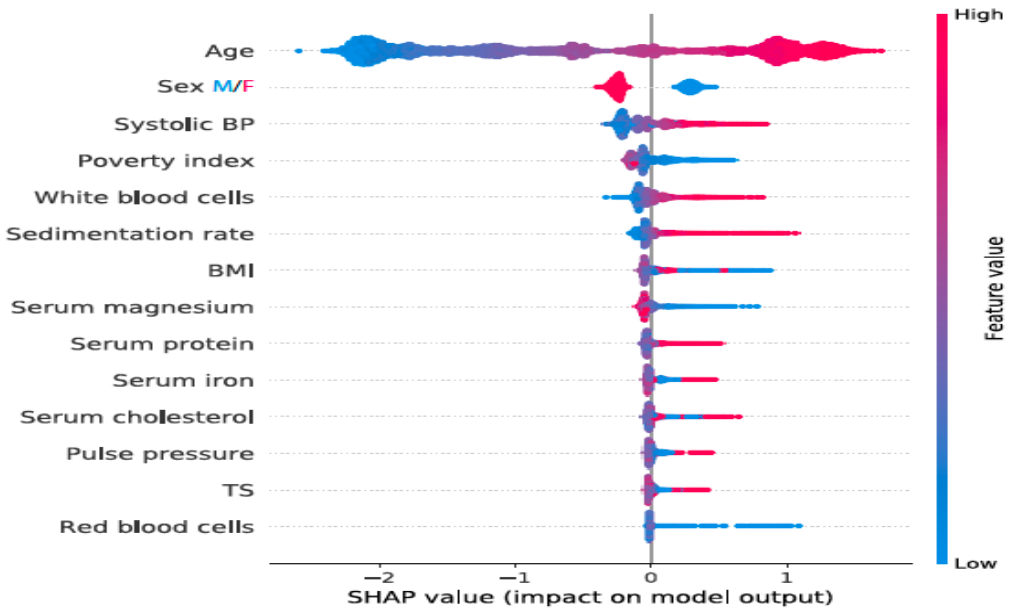

Figura: SHAP - output [2]

Artigo 04

1. Identifying Implementation Bugs in Machine Learning Based Image Classifiers using Metamorphic Testing [4]

Metamorphic - overview

1. Uso do conceito de teste metamórfico para testar algoritmos de machine learning.
2. Solução não agnóstica dado que há necessidade de definir relação metamórfica para cada novo modelo
3. Os autores conseguem validar a solução criando bugs artificiais em algoritmos conhecidos de machine learning (como SVM) e aplicando a solução proposta.
4. Não há uso de bugs reais para avaliar o algoritmo

Metamorphic - funcionamento

1. São definidos relações metamórficas para cada um dos dois algoritmos de machine learning (SVM e Residual Network)
2. Os autores alteram o fonte dos algoritmos para chumbar uma semente aleatória fixa para todas as execuções
3. As relações metamórficas não devem causar alteração no output e função de perda no decorrer do treino
4. Com essas condições asseguradas, se ocorrer uma alteração na função de perda ou output há indício de bug

Metamorphic - exemplos de relações metamórficas

1. Alterar a ordem das instâncias de treino
2. Alterar a ordem das features de treino
3. Adicionar um valor constantes em determinadas features
4. Escalar as variáveis

Fim!

Agradeço a atenção

Contato

- E-mail: *adilson.khouri.usp@gmail.com*
- Phone: +55119444 – 26191
- Link Linkedin
- Link Curriculum Lattes
- GitHub pessoal

Referências

[1] M. T. Ribeiro, S. Singh, and C. Guestrin, ""why should i trust you?": Explaining the predictions of any classifier," in *Proceedings of the 22Nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ser. KDD '16. New York, NY, USA: ACM, 2016, pp. 1135–1144. [Online]. Available: http://doi.acm.org/10.1145/2939672.2939778

[2] S. M. Lundberg, G. G. Erion, and S.-I. Lee, "Consistent individualized feature attribution for tree ensembles." *CoRR*, vol. abs/1802.03888, 2018. [Online]. Available: http://dblp.uni-trier.de/db/journals/corr/corr1802.html#abs-1802-03888

[3] J. Zhang, Y. Wang, P. Molino, L. Li, and D. S. Ebert, "Manifold: A model-agnostic framework for interpretation and diagnosis of machine learning models," *CoRR*, vol. abs/1808.00196, 2018. [Online]. Available: http://arxiv.org/abs/1808.00196

[4] A. Dwarakanath, M. Ahuja, S. Sikand, R. M. Rao, R. P. J. C. Bose, N. Dubash, and S. Podder, "Identifying implementation bugs in machine learning based image classifiers using metamorphic testing," in *Proceedings of the 27th ACM SIGSOFT International Symposium on Software Testing and Analysis*, ser. ISSTA 2018. New York, NY, USA: ACM, 2018, pp. 118–128. [Online]. Available: http://doi.acm.org/10.1145/3213846.3213858